

DOI: 10.19650/j.cnki.cjsi.J1803286

基于一维卷积神经网络的滚动轴承自适应故障诊断算法^{*}

曲建岭 余 路 袁 涛 田沿平 高 峰

(海军航空大学青岛校区 青岛 266041)

摘 要: 现有的滚动轴承故障诊断算法依赖于人工特征提取和专家知识,然而滚动轴承复杂多变的工作环境使得传统的智能故障诊断算法缺乏自适应性。针对此问题,提出了基于“端到端”的自适应一维卷积神经网络(ACNN-FD)故障诊断算法。首先,将各类故障状态的原始振动信号进行有重叠分段预处理用于构建训练样本和测试样本;然后,将每个训练样本以某一尺度的“时间步”进行划分作为所建立的一维卷积神经网络模型的输入,利用深度网络结构实现对原始振动信号特征的自适应层级化提取;最后在输出端利用 Softmax 分类器输出诊断结果。通过轴承数据库实验表明算法能够实现高达 99% 以上的故障识别准确率,同时在不同负载下良好的泛化性能,具备实际应用的可行性。

关键词: 一维卷积神经网络;智能故障诊断;深度学习;振动信号;自适应特征提取

中图分类号: TH165.3 TN911.2 **文献标识码:** A **国家标准学科分类代码:** 510.40

Adaptive fault diagnosis algorithm for rolling bearings based on one-dimensional convolutional neural network

Qu Jianling, Yu Lu, Yuan Tao, Tian Yanping, Gao Feng

(Naval Aviation University Qingdao Branch, Qingdao 266041, China)

Abstract: Current intelligent fault diagnosis methods largely depend on manual feature extraction and expertise knowledge. However, the complex and changeable working environment of bearings make traditional fault diagnosis algorithms lack of adaptability. To solve this problem, an “end-to-end” adaptive fault diagnosis algorithm based on one-dimensional convolutional neural network called ADCNN-FD is proposed. Firstly, different fault signals of bearings are segmented into training and testing datasets. Then, all training samples divided by a certain “time steps” are utilized as input of the model, and the features are extracted from the raw temporal vibration signal by deep architecture adaptively and hierarchically. Finally, a Softmax classifier is utilized to output diagnosis results at the top of the model. Experiments of rolling bearing datasets demonstrate that the proposed method can not only achieve more than 99% fault recognition accuracy, but also obtain good generalization performance under variable loads, which is applicable in practice.

Keywords: one-dimensional convolutional neural network; intelligent fault diagnosis; deep learning; vibration signal; adaptive feature extraction

0 引 言

滚动轴承广泛应用于工业生产设备中,其健康状态对整个机械设备的性能、稳定性和使用寿命有巨大的影响^[1]。由于复杂而恶劣的工作环境,滚动轴承是最易于受到损坏的机械元件之一,微小的故障尺寸又难以直接观察,因此学术界普遍采用振动信号分析法实现对滚动

轴承故障状态的有效识别。近年来,随着机器学习研究的不断兴起,智能故障诊断算法逐渐成为故障诊断领域的主流算法^[2]。智能故障诊断算法分为特征提取、特征选择和故障分类 3 个部分。传感器采集的原始振动信号含有丰富的故障信息和大量的无用噪声,特征提取的目的是提取原始振动信号中与故障特性相关的特征用于后续的故障识别,常采用的方法包括时、频域统计特征分析^[3]、快速傅里叶变换^[4]、小波变换^[5]和时频图分析^[6]

收稿日期: 2018-03 Received Date: 2018-03

^{*} 基金项目: 国家自然科学基金(51505491)项目资助

等。特征选择策略在特征提取后进行,主要是摒弃特征中的不敏感、无用的特征,实现对特征的进一步精雕,使有效特征的个数进一步缩减,达到去伪存真的目的。常采用的方法有主成分分析法(principle component analysis, PCA)^[7],独立分量分析法(independent component analysis, ICA)^[8],流形学习^[9]等算法。最后一步是将筛选过的特征作为故障分类器的输入,通过训练分类器实现故障类型的识别,反向传播神经网络(back propagation neural network, BP-NN)^[10]和支持向量机(support vector machine, SVM)^[11]因其良好的鲁棒性被广泛作为故障诊断的后端分类器。上述传统的智能故障诊断算法的优点包括应用范围广泛,特征提取方法简单易行并且通过设置合适的分类器参数,可以部分满足故障诊断识别率的要求。然而,传统算法也存在着不可忽视的弊端,特征提取算法依赖于人工提取和领域内的专家知识,一种机械设备适用的特征可能在另一种设备中失效,需要不断的寻找、选择合适的特征用于故障诊断,增加了人工操作的难度和工作量;机械设备的负载不断变化,当前负载下提取的特征在其他负载下往往会出现偏差,影响模型的泛化能力。

近年来,深度学习理论逐渐成为机器学习领域中炙手可热的学习算法。其利用深度网络结构对输入样本进行层层特征提取,通过每一层的非线性激活函数实现特征的自动提取,摆脱了对人工特征提取和专家知识的依赖,目前已在自然语言处理^[12]、计算机视觉^[13]、性别分类^[14]等模式识别任务中取得了突破性进展。深度学习在故障诊断领域的应用方兴未艾。

文献[15]提出了基于堆叠自编码器的故障诊断算法,利用自编码器的输入和输出相等的特性,通过中间隐藏层的堆叠实现对故障特征的提取。为了提高故障识别的鲁棒性,文献[16]将去噪自编码器引入故障诊断中,通过在输入信号中随机缺失部分元素提高隐层提取特征的鲁棒性,改善了故障识别率。卷积神经网络(convolutional neural network, CNN)作为深度学习的一个重要分支,主要应用在二维和三维的图像序列的特征提取,近年来也有部分学者将CNN引入到故障诊断领域。文献[17]提出了基于CNN的齿轮箱故障诊断模型,其基本思想是提取齿轮箱各种故障状态信号的时、频域特征作为CNN的输入,构建了二维CNN网络。文献[18]提取滚动轴承信号的时频图作为二维CNN的输入,在同样的网络结构下实现了故障诊断。

以上算法虽然都用到了CNN,但CNN的输入仍然为人工提取的特征,CNN强大的特征自学习能力没有得到充分的利用,限制了故障识别率的进一步提高。同时,振动信号作为一维时间序列信号,各时刻的数据点具有关联性,若直接将其转换为二维形式,则原始序列中的空间

相关性会遭到破坏,与故障相关的信息可能会缺失。目前,以原始振动数据作为一维CNN输入,通过CNN网络输出诊断结果的研究尚处于探索阶段,公开发表的研究成果较少^[19]。本文尝试建立了基于一维CNN的“端到端”自适应故障诊断模型ACNN-FD:即以原始振动信号作为CNN的输入,通过引入“时间步”的概念实现对原始输入信号的分割,通过构建合适的一维CNN模型,使模型最终输出与输入样本对应的故障类别,完全不依赖于人工特征提取和专家知识,最大限度的利用CNN的深度网络实现特征自学习,构建智能故障诊断网络。

1 一维卷积神经网络

CNN属于典型前馈神经网络,本质是通过建立多个滤波器提取输入数据的特征。这些滤波器对输入数据进行逐层卷积和池化,层层提取蕴含在输入数据中的拓扑结构特征。随着网络层数的逐渐增加,提取的特征不断抽象,最终从原始输入数据中得到具有平移旋转不变性的鲁棒特征。

CNN网络自身具有稀疏连接和权值共享的特性。其中,稀疏连接利用空间拓扑结构建立相邻层之间的非全连接空间关系用于降低模型需要训练的参数个数;权值共享用于避免算法过拟合。除此之外,池化操作利用数据本身具有的局部性特征,减少数据维度的同时优化网络结构,提高特征的鲁棒性。

一个典型的CNN网络通常包含输入层、卷积层、池化层、全连接层和输出层。在CNN的前期特征提取算法中,通过交替利用卷积层和池化层进行输入数据特征的层层提取,接近输出层则采用普通多层神经网络。在卷积层中,卷积核对前一层输出的特征矢量进行卷积操作,利用非线性激活函数构建输出特征矢量,每一层的输出均为对多输入特征的卷积结果,其数学模型可以描述为:

$$x_j^l = f\left(\sum_{i \in M_l} x_i^{l-1} \times k_{ij}^l + b_j^l\right) \quad (1)$$

其中, M_l 为输入特征矢量; l 为第 l 层网络; k 为卷积核; b 为网络偏置; x_j^l 为第 l 层输出; x_i^{l-1} 为第 l 层输入。在CNN中,非线性激活函数通常选择修正线性单元(rectified linear unit, ReLU),ReLU的优势在于使一部分神经元的输出为0,提高网络的稀疏性,并且减少了参数的相互依存关系,缓解了过拟合问题的发生。ReLU的公式化表述如下:

$$a_i^{l+1}(j) = f(y_i^{l+1}(j)) = \max\{0, y_i^{l+1}(j)\} \quad (2)$$

式中: $y_i^{l+1}(j)$ 表示卷积操作的输出值; $a_i^{l+1}(j)$ 是 $y_i^{l+1}(j)$ 的激活值。

池化层是对上一层数据的缩放映射,在实际应用中常采用最大池化算子,最大池化算子在输入的特征中提

取局部最大值,降低可训练参数数目和提高特征的鲁棒性。最大池化的变换函数如下所示:

$$P_i^{l+1}(j) = \max_{(j-1)W+1 \leq t \leq jW} \{q_i^l(t)\} \quad (3)$$

式中: $q_i^l(t)$ 表示第 l 层第 i 个特征矢量中第 t 个神经元的值, $t \in [(j-1)W+1, jW]$; W 为池化区域的宽度; $P_i^{l+1}(j)$ 表示第 $l+1$ 层神经元对应的值。

CNN 的输出部分包括对最后一个池化层的输出进行首尾全连接,之后采用 Softmax 分类器解决多分类问题,模型可表述为:

$$O = f(b_o + w_o f_v) \quad (4)$$

式中: f_v 为特征矢量; b_o 、 w_o 分别为偏差向量和权值矩阵。

一维 CNN 网络的输入为一维数据,因此其卷积核也相应的采用一维结构,每个卷积层和池化层的输出也相应的为一维特征矢量。在某一采样频率下机械设备的振动数据能够覆盖一个完整冲击的周期需要几十个数据点甚至几百个数据点,因此输入数据的数据点数通常在 10^2 数量级,若卷积核尺寸太小,则覆盖完整输入需要的卷积操作会显著增加,相应地,算法的运算时间也会显著增加。若卷积核尺寸太大,则无法精确定位输入数据中的特征,提取的特征可能会不明显且包含较多的冗余信息。为了保证卷积核能够充分的提取输入信号的特征,本文引入“时间步”的概念,即将一个完整的输入数据以时间步进行分割,分割成数据点较少的输入数据作为 CNN 网络的输入,保证了运算速度的同时又将较小的卷积核用于对输入特征的有效提取。

2 ACNN-FD 智能故障诊断算法

2.1 ACNN-FD 算法模型

CNN 虽然已在故障诊断中得到了应用,然而,前

述的基于 CNN 的智能故障诊断算法的模型只是将 CNN 用于特征提取后的进一步处理,并没有充分 CNN 网络强大的自学习能力,缺乏自适应性。另一方面,上述算法更多的还是依赖于人工特征提取和信号处理专家的领域内知识,因此受限于特征提取的数量, CNN 的网络结构一般只有一层或两层,而蕴含在原始信号中的非线性特征往往需要多层网络才能充分提取。因此,本文提出了基于 ACNN-FD 的自适应智能故障诊断算法。

本文构建的网络结构如图 1 所示,包括 3 部分:输入层、特征提取层以及分类层。输入层的作用是将原始振动信号进行分段预处理,并根据设定的时间步长分割输入信号。特征提取层包含卷积层和池化层,接收来自输入层的振动数据,利用卷积层中的多个卷积核实现对原始振动信号的特征提取,得到多个特征矢量。最大池化算子实现对特征矢量维数的约简,同时提高非线性特征的鲁棒性。交替的多个卷积池化层实现对输入信号非线性特征的层级式提取。分类层由两个全连接层组成,其中第 1 个全连接层实现对特征的“展平”操作,即将所有特征矢量首尾连接组成一维向量。第 2 个全连接层的神经元个数与故障类别数目保持一致,利用 Softmax 回归分类器实现目标输出类别。Softmax 回归模型是逻辑回归模型在多类分类问题的推广,类标签 y 具有向量形式,表明当前样本的类别在所有可能类别中的分布概率,Softmax 回归模型的损失代价函数可以表示为:

$$J(\theta) = -\frac{1}{m} \left[\sum_{i=1}^m \sum_{j=1}^k 1\{y_i = j\} \lg \frac{e^{\theta_j^{x_i}}}{\sum_{k=1}^k e^{\theta_k^{x_i}}} \right] \quad (5)$$

其中, (x_i, y_i) 是训练样本; m 为样本个数; $y_i \in \{1, 2, \dots, k\}$ 为样本所属类别; θ 为训练模型参数集,用于最小化当前代价函数。




图1 一维 CNN 模型

Fig. 1 Structure of 1D CNN

2.2 样本扩充

原始振动数据是一维时间序列信号,而实现深度学习的自适应故障诊断算法的前提条件之一是需要有大量的训练样本作为支撑,考虑到滚动轴承振动信号的主要信息蕴含在不同状态产生的冲击,因此,采用有重叠训练样本分割的方法实现训练数据扩容。分割示意图如图2所示。相比于无重叠样本分割方式,采用有重叠的样本分割策略既可以尽可能多的保留相邻元素之间的相关性,同时可以提高参与模型训练的样本数量,使模型尽可能学习到更具有鲁棒性的特征用于分类。在样本分割长度的选择上,较短的样本分割长度可以节省训练时间、提高模型的收敛速度,但是也会使样本中含有的信息量较少,在后续的非线性特征提取中会缺失部分信息,影响识别率;而较长的样本分割长度则会增加算法的收敛速度,影响故障检测模型的实时性。因此,选择合适的样本长度对于兼顾较高的故障识别率和较快的收敛速度至关重要。




图2 样本扩充示意图

Fig. 2 Schematic diagram of sample augmentation

对不同故障状态下的原始振动信号以一定的重叠比例 η 进行分割,并构建训练集和测试集。设某一故障状态下的振动信号 *signal* 的长度为 N , 设置样本长度为 len , 则以重叠率 η 进行样本扩充的实现方式为:

1) 获得在当前信号长度下的最大可分割样本数量:

$$m = \left\lfloor \frac{N - len}{len \times \eta} \right\rfloor \quad (6)$$

其中: $\lfloor \cdot \rfloor$ 为向下取整运算符。

2) 获取每个分割样本。第 i 个样本在原始振动信号 *signal* 的位置可以表示为:

$$x_i = \text{signal} [(i-1) \times len \times h + 1 : (i-1) \times len \times h + len] \quad i \in [1, m] \quad (7)$$

x_i 为分割后的数据样本,可以设定任意重叠比例 η 满足对不同数据样本规模的需求。

2.3 ACNN-FD 的训练

完成训练样本的准备后,将 RMSProp 优化算法^[20]用于模型训练。RMSProp 优化器可以有效防止深度学习过程中的过早收敛问题,适合于处理非平稳数据。损失函数 $L(\cdot)$ 采用最小均方误差 (mean square error, MSE)。如下式所示:

$$MSE = \frac{\sum_{i=1}^N (x_{\text{pred}}^i - x_{\text{true}}^i)^2}{N} \quad (8)$$

式中: x_{pred}^i 表示第 i 个样本的预测类别; x_{true}^i 表示第 i 个样本的真实类别。训练模型的基本实现步骤如下。

输入: 全局学习速率 ε , 初始化参数 θ , 数值稳定量 $\delta = 10^{-6}$, 衰减速率 ρ

中间变量: 梯度累积量 r

While 没有达到停止准则 do

从训练集中无放回随机抽取小批量 m 个样本 $\{x_1, x_2, \dots, x_m\}$ 及其对应输出类别 $\{y_1, y_2, \dots, y_m\}$ 。

计算梯度:

$$\hat{g} \leftarrow \frac{1}{m} \nabla_{\theta} \sum_i L(f(x_i; \theta), y_i)$$

累积平方梯度: $r \leftarrow \rho r + (1 - \rho) \hat{g} \odot \hat{g}$

计算参数更新: $\Delta \theta = -\frac{\varepsilon}{\delta + \sqrt{r}} \odot \hat{g}$

应用更新: $\theta \leftarrow \theta + \Delta \theta$

End while

3 实验

3.1 实验数据来源

为验证本文所提出算法的有效性,采用美国凯斯西储大学 (case western reserve university, CWRU) 的开放轴承数据库 (<http://csegroups.case.edu/bearingdatacenter/home>) 的样本进行实验分析,轴承故障产生的实验台如图3所示。一个 1491.4 W 的三相感应电动机轴 (左侧) 产生驱动力,一个测力计 (右侧) 用于产生额定负载,通过扭矩传感器的自动对准系统将二者连接在一起。两个加速度传感器分别安装在电机的驱动端和风扇端用于采集故障轴承的振动信号。使用电火花加工技术分别在轴承的内圈、外圈和滚动体上引入单点缺陷,故障尺寸分别为 7、14 和 21 in,以 12 kHz 采样频率采集不同负载下的故障轴承振动数据用于实验分析。

本文实验样本选取 1 hp 下 10 种故障状态振动信号,每类样本以 50% 的重叠率进行分割实现样本集扩容,具体实验样本信息如表 1 所示。每种轴承状态随机选择 50% 的样本用于模型训练,50% 的样本用于模型测试。

3.2 ACNN-FD 的参数选择

构建 CNN 模型中,选择合适的模型参数可以在保证较高分类正确率的前提下加快模型的训练速度,因此为了尽可能覆盖所有参数选择的可能,针对构建




图 3 CWRU 实验台

Fig. 3 Test rig of CWRU

表 1 实验样本组成

Table 1 Composition of experimental samples

样本类型	样本长度	样本数目	类别标记
正常	1 024	500	0
内圈故障(7 in)	1 024	500	1
外圈故障(7 in)	1 024	500	2
滚动体故障(7 in)	1 024	500	3
内圈故障(14 in)	1 024	500	4
外圈故障(14 in)	1 024	500	5
滚动体故障(14 in)	1 024	500	6
内圈故障(21 in)	1 024	500	7
外圈故障(21 in)	1 024	500	8
滚动体故障(21 in)	1 024	500	9

表 2 不同优化器和学习率实验结果

Table 2 Experiments of different optimizers and learning rates

学习率	0.000 1		0.001		0.01		0.1		1	
优化器	Train	Test	Train	Test	Train	Test	Train	Test	Train	Test
准确率/%										
Adadelta	10.00	10.00	10.00	10.00	28.42	38.36	97.13	98.26	98.73	98.52
Adam	98.04	98.42	99.56	98.79	94.40	95.66	10.00	10.00	10.00	10.00
RMSprop	98.21	98.57	99.77	99.00	97.44	98.17	10.00	10.00	10.00	10.00

2) 卷积层神经元数目

在有监督学习任务中,从训练样本中学习不同类别的数据内部结构特征是实现较高分类正确率的前提。在 CNN 中,从训练样本自适应提取特征通过卷积层中的神经元实现。为了充分提取不同类别训练样本中具有差别性的特征信息,可以采用以下两种方式进行:增加卷积层的数目和增加卷积层中神经元的数目。

前者一般应用于输入样本为图像的模型中,考虑到本文所处理的是一维信号,样本维数较低,若采用第一种方式则会增加模型的训练时间和模型需要训练的参数,

ACNN-FD 模型需要考虑的几个超参数进行实验,通过实验确定可以影响模型训练速度和分类正确率的超参数有优化器类型、优化器学习率、每个卷积层含有的卷积核数目以及每批次处理样本的数目。文献[16]中指出,在设置深度学习隐含层神经元数目时,遵循后一层神经元数目不超过前一层神经元数目一半的规律,本文采纳该建议作为配置隐含层神经元数目的依据。

1) 优化器及学习率

针对不同的深度学习模型和分类任务,选择合适的优化器及最优的学习率对于提高模型训练速度和分类准确率具有重要作用,因此,考虑本文所构建的 CNN 模型及分类任务,选择的备选优化器有 RMSprop、Adam 和 Adadelta 3 种优化器,同时考虑不同的学习率设置对于实际收敛速度的影响,采取不同的学习率用于模型训练,每组优化器及学习率分别进行 10 次实验,以训练集(Train)和测试集(Test)的平均正确率作为评价指标,实验结果如表 2 所示,其中粗体标注的数据为各个优化器的最佳分类结果(下同)。

由表 2 可以看出,RMSprop 和 Adam 优化器的实验结果相近,在学习率为 0.001 时可以达到最佳的分类结果,而随着学习率的增加,分类结果出现了严重的下降,而 Adadelta 优化器则与上述两者相反,当学习率较低时分类结果较差,在学习率为 1 时达到最佳分类效果,横向对比各自优化器的最佳分类结果,可以看出采用 RMSprop 优化器可以兼顾训练集和测试集的最高识别率。因此选择 RMSprop 优化器,优化率设置为 0.001。

在训练样本数目与维数均较少的情况下,过多的模型参数可能会引起过拟合问题。因此,本文采取第二种方式,即在固定卷积层数目为 2 层的前提下,考察不同卷积核配置方式对模型训练样本和测试样本分类准确率的影响,同时加入训练时间作为参考评价指标。

实验结果如表 3 所示,考察神经元配置方式为(256, 128)的实验可以看出,由于卷积核数目的增加,提高了模型对于训练样本正确识别的能力,但带来了更多的训练时间,且在测试集中的识别率并不是最佳。而在配置方式为(64, 32)的模型中,在兼顾较高训练集识别率的基

基础上,达到了最佳的测试集识别率,且模型的训练时间与最短耗时相近,因此在 ACNN-FD 模型中采用(64,32)的参数配置方案。

表 3 不同神经元配置方式对识别率的影响

Table 3 Effect of different neuron configurations on recognition rate

神经元配置	平均识别率 $\times 100\%$		平均训练时间/s
	Train	Test	
256,128	99.66	98.93	38.33
256,64	99.41	98.89	28.33
128,64	99.50	98.69	25.00
128,32	99.44	98.60	23.33
64,32	99.62	99.44	18.67
64,16	99.36	98.86	16.52
32,16	98.94	98.62	16.33

3) 批处理样本数目

深度学习的训练样本数目较多,如果参数更新以单个样本的迭代方式进行则极易陷入局部最优,严重限制了模型的泛化性能。通常深度学习模型通过将训练样本划分成多个批次(batch)实现对参数的更新,即使样本规模较大时依然可以实现收敛。因此,每批次处理样本的数目对于模型的正确识别率有重要意义。若批处理样本数目较少,则模型的训练时间增加,且易陷入局部最优;若批样本数目较多,则无法保证模型参数的最佳优化方向。设置不同的批处理样本数目进行实验,实验结果如表 4 所示,可见在批处理数为 64 时可以达到最佳的测试集识别率,同时训练集识别率和训练时间与最佳结果相近,因此选择批处理数为 64。

表 4 批处理样本数目对识别率的影响

Table 4 Effect of batch number of samples on recognition rate

批处理样本数目	平均识别率 $\times 100\%$		平均训练时间/s
	Train	Test	
16	99.32	98.68	24.32
32	99.60	98.77	21.67
40	99.29	98.89	18.00
64	99.45	99.60	16.67
80	99.22	98.61	15.67
128	99.25	98.64	17.33
256	99.01	98.68	19.33
512	97.65	98.57	19.67

3.3 实验结果

ACNN-FD 算法最终确定的模型参数如表 5 所示。

表 5 ACNN-FD 各参数值设置

Table 5 Parameter settings of ACNN-FD

参数名称	参数值
卷积层数	2
池化层数	2
卷积核大小	3×1
池化尺寸	2
优化器	RMSprop
优化器学习率	0.001
卷积层神经元数目	(64,32)
时间步个数	32
批处理个数	64
最大迭代次数	50

虽然设定最大迭代次数为 50,但本文引入了 Early-Stopping 机制,当模型的损失函数在一定步数内不再显著变化时即停止模型训练,用于防止深度学习的过拟合现象。训练集和测试集的准确率和损失函数值如图 4 所示。可以看出,通过 Early-Stopping 机制,在第 12 次迭代后就达到模型的终止条件,停止模型训练,同时,模型在测试集的准确率略高于训练集,而损失函数值略低于训练集,表明模型训练效果良好,没有发生过拟合现象。




图 4 训练集和测试集准确率和损失函数曲线

Fig. 4 Curves of accuracy and loss function of training and testing datasets

经过 12 次迭代后,模型输出在测试集的平均准确率为 99.6%。为了更清楚的展示模型在测试集中各个类别的识别结果,引入混淆矩阵对实验结果进行详细分析,如图 5 所示。除内圈 14 in 故障外,其余 9 种状态类型都能得到 100% 的识别。表明本文算法具有较高的故障识别率。




图5 测试集识别结果

Fig. 5 Experimental results of testing datasets

为了进一步表明每个卷积池化层对不同类别特征的学习能力,引入流形学习中的 t-SNE^[21] (t-distributed stochastic neighbor embedding) 维数约简算法提取不同层级的输出向量的前2维元素进行特征可视化。实验结果如图6所示。图6(a)为输入的原始样本的分布结果,由于振动信号本身存在的冗余性,导致各个类别难以进行区分。经过第1个卷积池化层的学习后,输出的样本分布有了显著的变化,大部分样本都聚集在各自的区域,但仍有不少样本没有聚拢,散落在相邻的类别之间。第2个卷积池化层的输出结果如图6(c)所示,相较于前一层各个类别的样本更加聚拢,但仍有少量样本产生了误分,例如第8类和第4类的部分样本中掺杂有异类样本。本模型中含有2个全连接层,由于第2个全连接层只是用于分类,因此仅对第1个全连接层的样本进行可视化,结果如图6(d)所示,可见除第5类样本含有部分异类外其余样本均聚拢在相应的区域,与图5的混淆矩阵的结果相符。最终测试集上的整体识别率为99.6%。

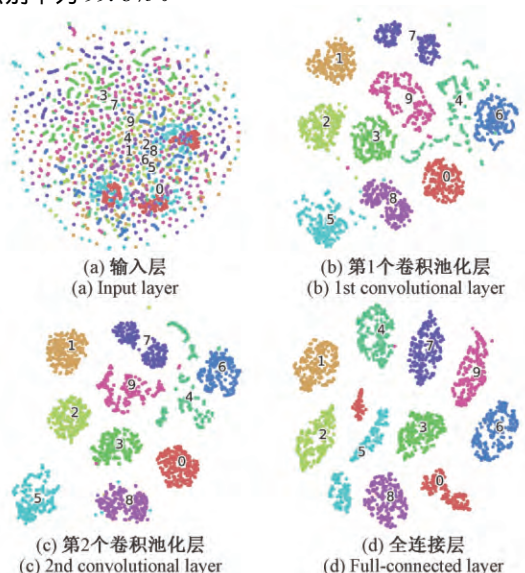


图6 不同层级的可视化输出

Fig. 6 Visualization of different layers

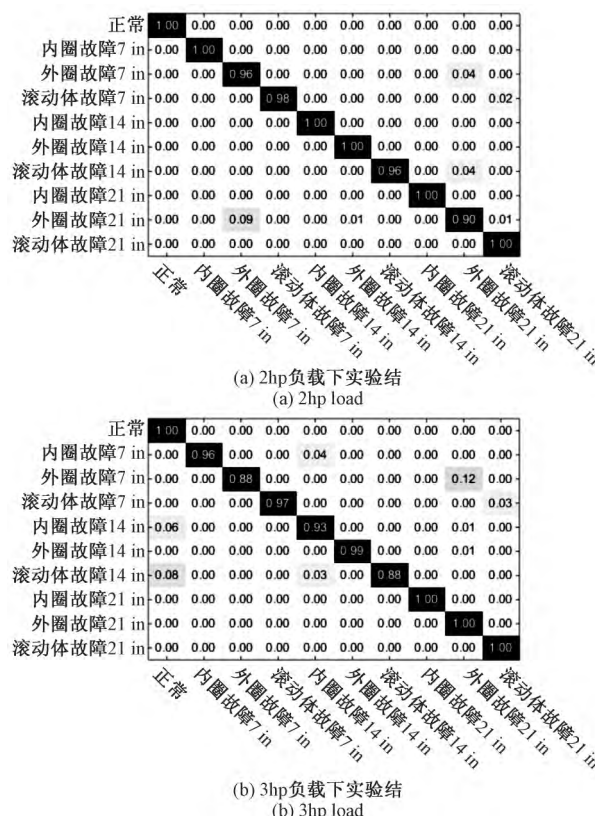


图7 不同负载下实验结果

Fig. 7 Experimental results under different loads

3.4 泛化性能实验

在实际的机械设备中,轴承上的负载可能会出现变化,因此本文对 ACNN-FD 模型的泛化性能进行了实验。训练集仍采用 1hp 下的负载进行模型训练,测试集分别选取 2 hp 和 3 hp 负载下相对应的 10 种故障状态的样本。模型参数设置与表 5 一致。利用混淆矩阵对实验结果进行表示,如图 7 所示。两种负载下的故障识别率分别为 98.0% 和 96.1%,仍然保持了较高的故障识别率。对误分类的样本进行分析,以负载 3 hp 下的外圈 7 in 故障为例,其正确率为 88%,有 12% 的样本被误分为外圈 21 in 故障,虽然故障尺寸不同,都将故障定位为外圈故障,说明 ACNN-FD 模型学习到了表征外圈故障的鲁棒的非线性特征,对于实际设备发生故障后的快速定位具有参考意义。

3.5 与其他算法对比实验

为验证本文算法与目前主流智能故障诊断算法的识别性能,将 BP-NN、SVM、堆叠去噪自动编码器(stacked denoised autoencoder, SDA)和文献[17]4种算法作为对比算法进行实验,每种算法反复进行实验 20 次,实验结果如表 6 所示。从表 6 可以看出,采用深度学习的 SDA

算法具有高达 97.6% 的识别率,而 BP-NN 和 SVM 由于具有浅层结构,限制了识别率的进一步提升。值得指出的是,虽然文献[17]采用了先进的 CNN 方法,但 CNN 的输入为人工提取的特征值,本质上并没有发挥 CNN 强大的非线性特征学习能力的优势,因此其识别率较本文算法仍然有差距。同时,本文算法的识别率结果波动较小,进一步验证了本文算法提取特征的鲁棒性和良好的泛化能力。

表 6 不同算法实验结果

Table 6 Experimental results of different methods

算法	识别率(×100%)		
	1 hp	2 hp	3 hp
BP-NN	85.5 ± 1.5	75.5 ± 2.2	70.2 ± 3.8
SVM	90.3 ± 1.4	85.3 ± 1.8	82.5 ± 2.0
SDA	97.6 ± 0.3	96.5 ± 0.4	96.0 ± 0.5
文献[17]	93.5 ± 1.2	88.3 ± 1.5	90.5 ± 1.5
本文	99.4 ± 0.2	97.9 ± 0.3	95.5 ± 0.5

3.6 实测航空发动机故障诊断实验

为验证本文算法在实际大型机械设备故障诊断中应用的可行性,将本文所构建的 ACNN-FD 算法应用于某型直升机航空发动机故障诊断中。实验数据来源于该型直升机涡轴发动机多台次、多架次试车时采集的 4 种转子健康状态:正常状态、转子不平衡、转子松动和碰摩,采用

等弧度采样方式,每周周期采集 128 个数据点,典型振动信号如图 8 所示。

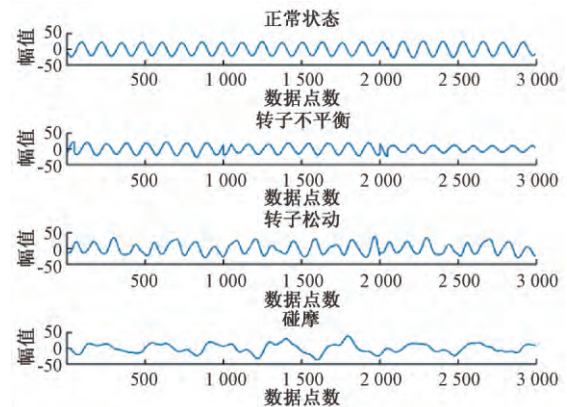


图 8 各状态典型振动信号

Fig. 8 Typical vibration signals of different faults

利用本文所提出的 ACNN-FD 自适应故障诊断算法进行实验,通过基于网格搜索的最优参数选择算法,最终确定的模型参数设置与表 5 保持一致。通过有重叠的样本分割方式实现对数据集样本的扩容,最终 4 类故障状态各自含有 600 个数据样本,其中训练样本与测试样本均为 300 个,经过 18 次迭代后达到收敛条件,最终在测试集中的准确率为 96.5%。

为避免偶然性,每种算法分别进行 10 次实验,取 10 次实验的平均结果作为最终实验结果。实验结果如表 7 所示。

表 7 不同算法实验结果

Table 7 Experimental results of different methods

算法	识别率(×100%)				
	正常	不平衡	碰摩	松动	综合识别率
BP-NN	90.3 ± 0.8	84.3 ± 1.5	80.2 ± 1.3	88.3 ± 0.8	85.7 ± 1.0
SVM	92.3 ± 0.5	88.3 ± 0.8	85.3 ± 0.7	90.3 ± 0.7	89.0 ± 0.6
SDA	99.0 ± 0.3	94.0 ± 0.4	90.7 ± 0.6	98.2 ± 0.5	95.4 ± 0.6
文献[17]	98.3 ± 0.2	94.3 ± 0.5	86.6 ± 0.4	98.7 ± 0.4	94.5 ± 0.3
本文	99.9 ± 0.1	96.0 ± 0.5	90.5 ± 0.5	99.9 ± 0.1	96.5 ± 0.3

由表 7 可见,本文算法相较于其他对比算法具有最高的识别率,同时算法的稳定性也优于其他算法,验证了本文算法应用于实际装备故障诊断中的可行性。

4 结 论

ACNN-FD 是一种基于卷积神经网络的自适应故障诊断算法,相比于传统算法其具有以下 3 个优势: 1) 不

需要人工特征提取,直接将原始振动数据作为 CNN 的输入,在 CNN 的输出端即为故障的识别结果,节省了使用者的操作难度; 2) 得益于卷积神经网络的深度结构,使得蕴含在原始振动信号的本质特征通过逐层非线性特征提取实现,深度学习的强大的非线性特征自学习能力得到了充分的运用; 3) 该算法具有良好的鲁棒性和泛化性能,即使负载发生变化,仍然保持较高的故障识别率。但是需要指出本文算法仍然存在不足之处: 相较于浅层算法,本文算法的模型训练时间较长,每批

次处理迭代耗时约为 1.2 s; 模型参数的选取需要反复试验才能选取合适的参数。下一步的研究重点应为根据待检测信号的性质设计自适应的模型参数选择算法, 提高算法的运算效率。

参考文献

- [1] JIA F, LEI Y, LIN J, et al. Deep neural networks: A promising tool for fault characteristic mining and intelligent diagnosis of rotating machinery with massive data [J]. Mechanical Systems & Signal Processing, 2016(72-73): 303-315.
- [2] 余路, 曲建岭, 高峰, 等. 基于改进稀疏编码的微弱振动信号特征提取算法 [J]. 仪器仪表学报, 2017, 38(3): 711-717.
YU L, QU J L, GAO F, et al. Feature extraction of weak vibration signal based on improved sparse coding [J]. Chinese Journal of Scientific Instrument, 2017, 38(3): 711-717.
- [3] 蔡剑华, 胡惟文, 王先春. 基于高阶统计量的滚动轴承故障诊断方法 [J]. 振动、测试与诊断, 2013, 33(2): 298-301.
CAI J H, HU W W, WANG X CH. Rotor fault diagnosis based on Higer-order statistics [J]. Journal of Vibration, Measurement & Diagnosis, 2013, 33(2): 298-301.
- [4] HE Y, HUANG J, ZHANG B. Approximate entropy as a nonlinear feature parameter for fault diagnosis in rotating machinery [J]. Measurement Science & Technology, 2012, 23(4): 45603-45616.
- [5] 龙英, 何怡刚, 张镇, 等. 基于信息熵和 Haar 小波变换的开关电路故障诊断新方法 [J]. 仪器仪表学报, 2015, 36(3): 701-711.
LONG Y, HE Y G, ZHANG ZH, et al. Switched-curent fault diagnosis based on entropy and Haar wavelet transform [J]. Chinese Journal of Scientific Instrument, 2015, 36(3): 701-711.
- [6] 张云强, 张培林, 吴定海, 等. 基于 CSLBP 的轴承信号时频特征提取方法 [J]. 振动、测试与诊断, 2016, 36(1): 22-27.
ZHANG Y Q, ZHANG P L, WU D H, et al. Time-frequency feature extraction method based on cs-lbp for bearing signals [J]. Journal of Vibration Measurement & Diagnosis, 2016, 36(1): 22-27.
- [7] HU B, LI B. A new multiscale noise tuning stochastic resonance for enhanced fault diagnosis in wind turbine drivetrains [J]. Measurement & Technology, 2016, 27(2): 025017.
- [8] HE W, ZI Y, CHEN B, et al. Automatic fault feature extraction of mechanical anomaly on induction motor bearing using ensemble super-wavelet transform [J]. Mechanical Systems & Signal Processing, 2015(54-55): 457-480.
- [9] 苏祖强, 汤宝平, 姚金宝. 基于敏感特征选择与流形学习维数约简的故障诊断 [J]. 振动与冲击, 2014, 33(3): 70-75.
SU Z Q, TANG B P, YAO J B, et al. Fault diagnosis method based on sensitive feature selection and manifold learning dimension reduction [J]. Journal of Vibration and Shock, 2014, 33(3): 70-75.
- [10] WANG H, CHEN P. Intelligent diagnosis method for rolling element bearing faults using possibility theory and neural network [J]. Computers & Industrial Engineering, 2011, 60(4): 511-518.
- [11] 焦卫东, 林树森. 整体改进的基于支持向量机的故障诊断方法 [J]. 仪器仪表学报, 2015, 36(8): 1861-1870.
JIAO W D, LIN SH S. Overall-improved fault diagnosis approach based on support vector machine [J]. Chinese Journal of Scientific Instrument, 2015, 36(8): 1861-1870.
- [12] 郑啸, 王义真, 袁志祥, 等. 基于卷积记忆神经网络的微博短文本情感分析 [J]. 电子测量与仪器学报, 2018, 32(3): 195-200.
ZHENG X, WANG Y ZH, YUAN ZH X, et al. Sentiment analysis of micro-blog short text based on convolutional memory neural network [J]. Journal of Electronic Measurement and Instrumentation, 2018, 32(3): 195-200.
- [13] 李伟, 张旭东. 基于卷积神经网络的深度图像超分辨率重建方法 [J]. 电子测量与仪器学报, 2017, 31(12): 1918-1928.
LI W, ZHANG X D. Depth image super-resolution reconstruction based on convolution neural network, Journal of Electronic Measurement and Instrumentation, 2017, 31(12): 1918-1928.
- [14] 张婷, 李玉鑑, 胡海鹤, 等. 基于跨连卷积神经网络的性别分类模型 [J]. 自动化学报, 2016, 42(6): 858-865.
ZHANG T, LI Y J, HU H H, et al. A gender classification model based on cross-connected convolutional neural networks [J]. ACTA Automatica Sinica, 2016, 42(6): 858-865.
- [15] 郭亮, 高宏力, 张一文, 等. 基于深度学习理论的轴

- 承状态识别研究[J]. 振动与冲击, 2016, 35(12): 167-171.
- GUO L, GAO H L, ZHANG Y W, et al. Research on bearing condition monitoring based on deep learning[J]. Journal of Vibration and Shock, 2016, 35(12): 167-171.
- [16] LU C, WANG Z Y, QIN W L, et al. Fault diagnosis of rotary machinery components using a stacked denoising autoencoder-based health state identification[J]. Signal Processing, 2017, 130(C): 377-388.
- [17] CHEN Z Q, LI C, SANCHEZ R. Gearbox fault identification and classification with convolutional neural networks[J]. Shock and Vibration, 2015(2): 1-10.
- [18] 袁建虎, 韩涛, 唐建, 等. 基于小波时频图和 CNN 的滚动轴承智能故障诊断方法[J]. 机械设计与研究, 2017(2): 93-97.
- YUAN J H, HAN T, TANG J, et al. An approach to intelligent fault diagnosis of rolling bearing using wavelet time-frequency representation and CNN[J]. Machine Design and Research, 2017(2): 93-97.
- [19] 任浩, 屈剑锋, 柴毅, 等. 深度学习在故障诊断领域中的研究现状与挑战[J]. 控制与决策, 2017, 32(8): 345-358.
- REN H, QU J F, CHAI Y, et al. Deep learning for fault diagnosis: The state of the art and challenge[J]. Control and Decision, 2017, 32(8): 345-358.
- [20] GOODFELLOW I, BENGIO Y, COURVILLE A. Deep Learning[M]. Cambridge: MIT Press 2016.
- [21] HINTON G E. Visualizing high-dimensional data using t-SNE[J]. Vigilae Christianae, 2008, 9(2): 2579-2605.

作者简介



曲建岭, 1991 年于南京航空航天大学获得学士学位, 分别在 1998 年和 2001 年于西北工业大学获得硕士学位和博士学位, 现为海军航空大学青岛校区教授, 主要研究方向为模式识别与飞参数据应用。

E-mail: qujianling@tom.com.

Qu Jianling received his B. Sc. degree from Nanjing University of Aeronautics and Astronautics in 1991, M. Sc. and Ph. D. degrees both from Northwestern Polytechnical University in 1998 and 2001, respectively. Now, he is a professor in Qingdao Branch of Naval Aviation University. His current research interests include Pattern Recognition and applications of flight data.



余路(通信作者), 分别于 2012 年和 2014 年于海军工程大学获得学士学位和硕士学位, 现为海军航空大学青岛校区博士研究生, 主要研究方向为振动信号处理、稀疏编码和深度学习。

E-mail: yulu_china@163.com

Yu Lu (Corresponding author) received his B. Sc. and M. Sc. degrees both from Naval University of Engineering in 2012 and 2014, respectively. Now he is a Ph. D. candidate in Qingdao Branch of Naval Aviation University. His main research interests include vibration signal processing, sparse coding and deep learning.